

## REPRODUÇÃO EXPERIMENTAL: MACHINE LEARNING METHODS FOR TRAFFIC PREDICTION IN DYNAMIC OPTICAL NETWORKS WITH SERVICE CHAINS

Alex Rossoni Junior<sup>1</sup>  
Maxwell Eduardo Monteiro<sup>2</sup>

### RESUMO

A reprodução de resultados experimentais é uma etapa crucial para validar os achados de pesquisas científicas. Neste trabalho, realizamos um experimento com base no artigo "*Machine Learning Methods for Traffic Prediction in Dynamic Optical Networks with Service Chains*". O estudo original propôs uma metodologia para prever demandas de tráfego em redes ópticas dinâmicas que atendem cadeias de Funções de Rede Virtual (VNF), utilizando classificadores de aprendizado de máquina para otimizar métricas de desempenho da rede. Nossa reprodução foca em simular o impacto da precisão na previsão de demandas sobre o desempenho da rede, utilizando um ambiente baseado em Python. Especificamente, analisamos cenários com e sem conhecimento prévio das demandas de tráfego, comparando métricas como latência e perda de pacotes. Os experimentos foram conduzidos utilizando o MininetVM em uma plataforma VirtualBox.

**Palavras-chave:** Predição de tráfego, Redes ópticas dinâmicas, Cadeias de Funções de Rede Virtual (VNF), Aprendizado de máquina, Reprodução de experimento, Latência, Perda de pacotes, Simulação em Python, MininetVM, VirtualBox.

### ABSTRACT

The reproduction of experimental results is a crucial step in validating the findings of scientific research. In this work, we conducted an experiment based on the article "*Machine Learning Methods for Traffic Prediction in Dynamic Optical Networks with Service Chains*". The original study proposed a methodology for predicting traffic demands in dynamic optical networks serving Virtual Network Function (VNF) chains, using machine learning classifiers to optimize network performance metrics. Our reproduction focuses on simulating the impact of prediction accuracy on network performance, using a Python-based environment. Specifically, we analyze scenarios with and without prior knowledge of traffic demands, comparing metrics such as latency and packet loss. The experiments were conducted using MininetVM on a VirtualBox platform.

**Keywords:** Traffic Prediction, Dynamic Optical Networks, Virtual Network Function (VNF) Chains, Machine Learning, Experimental Reproduction, Latency, Packet Loss, Python Simulation, MininetVM, VirtualBox.

---

<sup>1</sup> Aluno na disciplina de Laboratório de Pesquisa I e do 5º período do curso de Sistemas de Informação no Instituto Federal do Espírito Santo (Ifes) – Campus Serra.

<sup>2</sup> Professor orientador na disciplina de Laboratório de Pesquisa I, Instituto Federal do Espírito Santo (Ifes) – Campus Serra.

# SUMÁRIO

<b>RESUMO.....</b>	<b>1</b>
<b>SUMÁRIO.....</b>	<b>2</b>
<b>INTRODUÇÃO.....</b>	<b>3</b>
Contexto.....	3
Objetivo.....	3
<b>METODOLOGIA.....</b>	<b>3</b>
Ferramentas utilizadas.....	3
Configuração do ambiente.....	4
Métodos e métricas de análise.....	4
Código do experimento em Python.....	4
<b>RESULTADOS.....</b>	<b>4</b>
Visão geral.....	4
Representações visuais.....	5
<b>CONCLUSÃO.....</b>	<b>6</b>
<b>REFERÊNCIAS.....</b>	<b>6</b>

# INTRODUÇÃO

## Contexto

As redes ópticas dinâmicas desempenham um papel essencial na infraestrutura moderna de comunicação, oferecendo alta capacidade e flexibilidade para lidar com o aumento exponencial do tráfego de dados. Em ambientes de rede dinâmicos, a previsão precisa da demanda de tráfego pode melhorar significativamente o desempenho da rede, permitindo otimizações de recursos e redução de custos operacionais. A previsão de tráfego também facilita a alocação eficiente de recursos em redes que atendem a Funções de Rede Virtual (VNF), essenciais para serviços como redes definidas por software (SDN) e virtualização de funções de rede (NFV).

O artigo *"Machine Learning Methods for Traffic Prediction in Dynamic Optical Networks with Service Chain"* propôs uma metodologia baseada em aprendizado de máquina para prever as demandas de tráfego em redes ópticas dinâmicas que suportam cadeias de VNF. Utilizando uma série de classificadores de aprendizado de máquina, o estudo demonstrou que é possível prever com alta precisão as demandas de tráfego com base nas observações passadas, proporcionando melhorias substanciais no desempenho da rede.

A motivação principal para este trabalho é validar a eficácia da metodologia proposta no artigo original e analisar seu impacto no desempenho da rede, considerando métricas como latência e perda de pacotes.

## Objetivo

Este trabalho tem como objetivo executar um experimento baseado no estudo original, com foco em simular o impacto da previsão de demandas de tráfego sobre o desempenho da rede, mais especificamente, analisando dois cenários: (i) quando há conhecimento prévio das demandas (previsões perfeitas) e (ii) quando não há conhecimento das demandas (demanda desconhecida). Para tanto, foi utilizado o ambiente MininetVM em uma máquina virtual do VirtualBox, com scripts implementados em Python.

# METODOLOGIA

## Ferramentas utilizadas

Para a reprodução do experimento, foram utilizadas as seguintes ferramentas:

1. MininetVM: Plataforma de simulação para redes virtuais dinâmicas, permitindo a emulação de topologias de rede e tráfego de dados.
2. VirtualBox: Ambiente de virtualização onde o MininetVM foi executado.
3. Python e matplotlib: Python foi a linguagem de programação utilizada para implementar o script de simulação e controle do experimento e matplotlib foi a biblioteca utilizada para gerar os gráficos com os resultados.

## Configuração do ambiente

O ambiente do experimento foi configurado utilizando o VirtualBox com uma imagem pronta fornecida pelo Mininet, o Mininet VM, que roda o sistema operacional Ubuntu 20.04 e já possui o Python instalado.

Durante a configuração da máquina virtual, foi necessário adicionar um adaptador de rede host-only conforme a documentação do Mininet.

Além disso, foi configurado o uso de pastas compartilhadas entre a VM e a máquina original, o que facilitou o desenvolvimento e execução dos experimentos, já que o Mininet VM não possui interface gráfica.

## Métodos e métricas de análise

No artigo original "Machine Learning Methods for Traffic Prediction in Dynamic Optical Networks with Service Chains", as métricas de desempenho centraram-se principalmente na taxa de previsão correta e na eficácia dos classificadores de aprendizado de máquina para prever as demandas de tráfego. Métricas de latência e perda de pacotes não foram explicitamente mencionadas como indicadores de avaliação no estudo original.

Apesar disso, a previsão de tráfego **impacta diretamente** o planejamento da rede, melhorando a alocação de recursos e a otimização das rotas de tráfego, o que influencia, por consequência, **na redução da latência e na diminuição da perda de pacotes**. Essas duas métricas são críticas para redes ópticas dinâmicas, já que um planejamento de tráfego eficiente pode evitar congestionamentos e otimizar o uso da infraestrutura disponível.

Portanto, embora o artigo não mencione diretamente essas métricas, no nosso experimento, a latência e a perda de pacotes foram adotadas como métricas para analisar o impacto da previsão de tráfego sobre o desempenho da rede. Redes mal dimensionadas tendem a apresentar maiores valores de latência e perda de pacotes, sendo, portanto, essenciais para avaliar a eficiência da metodologia de previsão proposta.

## Código do experimento em Python

O código do script usado para realizar o experimento pode ser encontrado completo em: [alexrossoni/LABPESQ-experiment: Reprodução de experimento de redes com Python e Mininet para disciplina de Laboratório de Pesquisa I - Ifes Campus Serra](#)

## RESULTADOS

### Visão geral

Os resultados a seguir, exemplos de dois dos diversos testes realizados com o script do experimento, mostram que o conhecimento prévio das demandas de tráfego tem um impacto positivo no desempenho da rede, refletido em uma redução significativa na latência e na perda de pacotes.

- Resultado 1:  
Demandas Conhecidas: Latência média de 0,01 ms e perda de pacotes de 0,18%.  
Demandas Desconhecidas: Latência média de 0,13 ms e perda de pacotes de 0,20%.
- Resultado 2:  
Demandas Conhecidas: Latência média de 0,01 ms e perda de pacotes de 0,11%.  
Demandas Desconhecidas: Latência média de 0,11 ms e perda de pacotes de 0,25%.

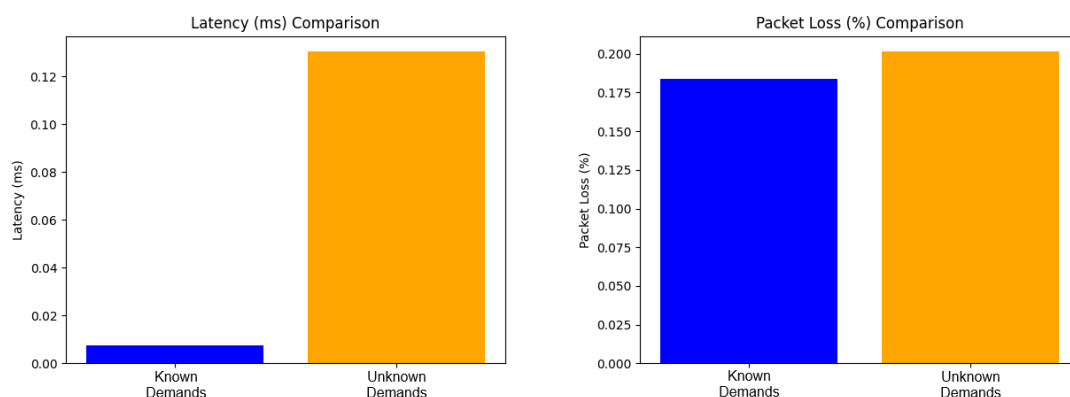
Esses resultados indicam que, em todos os cenários, o conhecimento prévio das demandas levou a uma **redução na latência e em perdas de pacotes** em comparação com a situação em que as demandas eram desconhecidas. Essa tendência reflete as observações feitas no estudo original, onde se destaca a importância da previsão de tráfego para melhorar o desempenho da rede.

Embora nosso experimento não tenha implementado diretamente classificadores de aprendizado de máquina, ele validou a hipótese de que um planejamento eficiente de tráfego baseado em previsões pode reduzir efetivamente as métricas de desempenho como latência e perda de pacotes.


A comparação entre os resultados de "Demandas Conhecidas" e "Demandas Desconhecidas" revela que, mesmo sem a implementação direta dos classificadores, a previsão precisa do tráfego pode ajudar na otimização da alocação de recursos e na melhoria geral da rede, alinhando-se com os achados do estudo original. Esses resultados também reforçam a ideia de que a previsão de tráfego contribui para melhor utilização dos recursos e redução de complexidade na alocação de rotas, como discutido nas conclusões do artigo.

## Representações visuais

Resultado 1:



## Resultado 2:



## CONCLUSÃO

Este trabalho buscou reproduzir e comparar os resultados do estudo "Machine Learning Methods for Traffic Prediction in Dynamic Optical Networks with Service Chains", focando no impacto da previsão de demandas de tráfego no desempenho de redes ópticas dinâmicas. A simulação realizada em MininetVM confirmou que o conhecimento prévio das demandas reduz latência e perda de pacotes, alinhando-se com as conclusões do estudo original.

Embora não tenha sido implementada a metodologia de aprendizado de máquina diretamente, a simulação validou a hipótese de que previsões precisas de tráfego podem melhorar a alocação de recursos e otimizar o desempenho da rede. O estudo original sugere que a previsão de tráfego pode reduzir a complexidade dos problemas de otimização de rede, e nossos resultados confirmam esse impacto.

Futuros trabalhos podem incluir a implementação dos classificadores de aprendizado de máquina utilizados no estudo original e a consideração de outras métricas de desempenho, como volume de demanda e tempo de retenção.

## REFERÊNCIAS

Szostak, D., Walkowiak, K.

Machine learning methods for traffic prediction in dynamic optical networks with service chains

(2019) International Conference on Transparent Optical Networks, 2019-July, art. no. 8840301,.